Паспорт инвестиционного тезиса

Дополнительный материал к конкурсной заявке

Исследовательское обоснование • архитектура • воспроизводимый микротест
9 ноября 2026 года

1. Что мы обосновываем

Концепция: помощник кредитного аналитика проверяет основания тезиса об изменении долговой нагрузки. AI предлагает структурированные факты и источники; правила проверяют формальные условия; инвестиционная интерпретация остаётся за человеком. Материал подтверждает обоснованность постановки задачи и показывает минимальный механизм контроля. Он не доказывает рыночный спрос, экономию времени или надёжность финансового продукта.

2. Исследовательские основания

FinanceBench: финансовый ответ нужно оценивать вместе с доказательством

Islam et al., 2023. FinanceBench содержит 10 231 вопрос с ответами и фрагментами доказательств. В работе проверены 16 конфигураций на 150 случаях, выполнена ручная оценка 2 400 ответов. Авторы сообщают ограничения исследованных LLM и RAG-конфигураций. Это обосновывает необходимость проверки источников и отдельного эталонного набора, но не доказывает качество нашего решения.

Ограничение переноса: результаты относятся к конфигурациям и данным исследования 2023 года; их нельзя представлять как оценку современных моделей или российского рынка. В частности, ошибки и отказы не следует объединять под названием «галлюцинации».

Источник: Islam et al. FinanceBench: A New Benchmark for Financial Question Answering. https://arxiv.org/abs/2311.11944

FinQA: расчёт должен иметь проверяемую программу

Chen et al., EMNLP 2021. FinQA объединяет вопросы по финансовым отчётам, экспертные ответы, поддерживающие факты и программы вычисления. Авторы рассматривают работу с текстом и таблицами и многошаговое численное рассуждение. Для проекта заимствуем принцип: хранить не только число-ответ, но и исходные значения, источники и исполняемый расчёт.

Ограничение переноса: FinQA не оценивает наш сценарий обновления инвестиционного тезиса и не подтверждает пригодность модели для РСБУ/МСФО. Данные могут служить методическим образцом, а не заменой локальной экспертной выборки.

Источник: Chen et al. FinQA: A Dataset of Numerical Reasoning over Financial Data. https://aclanthology.org/2021.emnlp-main.300/
Код и структура данных: https://github.com/czyssrs/FinQA

Вывод из источников

Нужна связка «утверждение — свидетельство — программа расчёта — ограничение вывода». Исследования поддерживают выбор проверяемого финансового QA как задачи. Они не подтверждают наше коммерческое преимущество: это предмет собственного эксперимента.

3. Схема MVP и граница доверия

- Вход: тезис аналитика и зафиксированные версии документов двух периодов.
- Парсер: текст, таблицы, страницы и координаты; исходные файлы сохраняются.
- Поиск + LLM: кандидаты в факты, определения, подтверждающие и противоречащие фрагменты.
- Проверки: нормализация единиц, периоды, периметр, определения и арифметика.
- Выход: карточки статусов с основаниями; спорные вопросы направляются аналитику.
- Обновление: новая версия проверки, сравнение оснований, неизменяемая история.

Граница доверия: наличие числа в документе не доказывает, что выбрана правильная строка. Технически валидный источник может не поддерживать утверждение. Проверка смысла извлечения и определений остаётся отдельной задачей. Отсутствие автоматического подтверждения интерпретации обеспечивается правилом, а не просьбой в промпте.

4. Выполненный микротест правил

Для этого материала выполнен микротест функции назначения статуса на трёх уровнях: 13 регрессионных кейсов, полный перебор всех 256 комбинаций входов со сверкой с независимо записанной таблицей решений и мутационная проверка самого теста. Проверяется только утверждение «новое нормализованное значение меньше старого», запрет автоматического подтверждения инвестиционной интерпретации и статус «уточните» при нескольких опорах с разными значениями. Числа 100, 80 и 120 условные; они не относятся к реальному эмитенту.

Случай	Статус	Результат
Снижение показателя	confirmed	Пройден
Рост показателя	contradicted	Пройден
Показатель не изменился	contradicted	Пройден
Нет источника	insufficient_data	Пройден
Нет значения	insufficient_data	Пройден
Компания и группа	not_comparable	Пройден
Разные определения	not_comparable	Пройден
Инвестиционная интерпретация	analyst_required	Пройден
Несколько опор с разными	clarify	Пройден

значениями		
Нет старого значения	insufficient_data	Пройден
Интерпретация без источника	analyst_required	Пройден
Разный периметр и нет значения	insufficient_data	Пройден
Несколько опор и разные определения	clarify	Пройден

Результат: 13 из 13 регрессионных кейсов; 256 комбинаций без расхождений с таблицей решений и без нарушений инвариантов; 6 из 6 мутантов убиты. Ошибку порядка правил (противоречие опор проверяется после сопоставимости) исходные 8 кейсов не обнаруживали — её ловят новые комбинационные кейсы и перебор. Это демонстрация заданного поведения, не оценка точности AI. Функция не выполняет OCR, поиск, сверку координат, распознавание периодов, нормализацию валют или семантическую проверку определений. Входные флаги сопоставимости заданы вручную. Финансовая применимость уменьшения показателя требует отдельной методики; отрицательная или нулевая EBITDA этим микротестом не рассматривается.

Воспроизведение: в корне репозитория github.com/SergeiUstiugov/thesis-passport выполнить python check_rules.py и python mutation_check.py. Требуется Python 3.9+; сторонние библиотеки не нужны. Скрипт записывает results.csv, results_exhaustive.csv и results_meta.json с временем запуска и хешем файла кейсов. Тот же прогон автоматически выполняется в GitHub Actions при каждом изменении.

5. Что предстоит доказать

- Потребность: интервью и хронометраж на реальных задачах аналитиков.
- Качество извлечения: разметка источников и корректности выбранных показателей.
- Польза правил: сравнение с базовым RAG на закрытых случаях.
- Экономия времени: полное время с чтением карточек и исправлениями.
- Переносимость: разные эмитенты, форматы и определения показателей.

Предлагаемый первый эксперимент: 30–50 пилотных утверждений по 3–5 эмитентам; ручной поиск, базовый RAG и MVP на сопоставимых заданиях без повторного решения одного случая одним аналитиком. Предварительный критерий продолжения — сокращение медианного времени не менее чем на 20% относительно ручного поиска без роста наблюдаемой доли существенных пропусков. Порог — проектное предложение, не результат исследования; окончательно он фиксируется после пилотной разметки и до закрытого теста. Малый пилот не докажет отсутствие роста риска статистически.

6. Честная формулировка готовности

Готовы: концепция, архитектурная схема, подбор научных оснований и воспроизводимый синтетический микротест статусов с полным перебором комбинаций и мутационной проверкой. Не заявляются как готовые: финансовый RAG-прототип, корпус российских эмитентов, результаты пользовательского эксперимента, промышленная интеграция и доказательство корректности реализации в Lean.